

PSA_Markdown

Valentina Muñoz-Kevin Chaparro

2026-05-29

cargar librerías

```
#install.packages("sf")
library(sf)

## Warning: package 'sf' was built under R version 4.5.3

## Linking to GEOS 3.14.1, GDAL 3.12.1, PROJ 9.7.1; sf_use_s2() is TRUE

library(dplyr)

##
## Adjuntando el paquete: 'dplyr'

## The following objects are masked from 'package:stats':
##
##   filter, lag

## The following objects are masked from 'package:base':
##
##   intersect, setdiff, setequal, union

#install.packages("sampling")
library(sampling)

## Warning: package 'sampling' was built under R version 4.5.3

library(readxl)
```

subir marco muestral y muestra probabilística

```
##1.1) subir bases de datos
base=st_read("MGN_ANM_MANZANA.shp")

## Reading layer `MGN_ANM_MANZANA' from data source
##   `C:\Users\valen\Documents\R studios\muestreo
## avanzado\parcial3\MGN_ANM_MANZANA.shp'
##   using driver `ESRI Shapefile'
## Simple feature collection with 504996 features and 108 fields
## Geometry type: MULTIPOLYGON
## Dimension:      XY
## Bounding box:   xmin: -81.73271 ymin: -4.226085 xmax: -66.96209 ymax:
## 13.38684
## Geodetic CRS:   MAGNA-SIRGAS

base_P=read_xlsx("BASE_PROBABILISTICA.xlsx")
##Filtrar y depuración
```

```
base_cund=base %>%
  filter(DPTO_CCDGO == "25") %>%
  filter(TVIVIENDA > 0)
base_NP=base_cund %>% filter(!COD_DANE_A %in% base_P$COD_DANE_A)
```

construcción de muestra no probabilística

```
#muestra no probabilística
base_NP <- base_NP %>%
  mutate(
    poblacion_joven = TP34_3_EDA + TP34_4_EDA,
    prop_apartamentos = ifelse(TVIVIENDA > 0, TP14_2_TIP / TVIVIENDA, 0),
    peso_no_prob = (prop_apartamentos + 0.1) * (poblacion_joven + 1) *
      (TVIVIENDA^1.1)
  )

#muestra no probabilística
set.seed(76984)
tamanho_no_prob <- 1500

base_NP <- base_NP %>%
  slice_sample(n = tamanho_no_prob, weight_by = peso_no_prob, replace =
    FALSE)
```

verificar sesgo

```
# 5. Diagnóstico de control para verificar que el sesgo se aplicó con éxito
cat("--- VERIFICACIÓN DEL SESGO GENERADO --- \n")

## --- VERIFICACIÓN DEL SESGO GENERADO ---

cat("Proporción prom. de apartamentos en Marco Original (Cundinamarca):",
  mean(base_cund$TP14_2_TIP / base_cund$TVIVIENDA, na.rm=TRUE), "\n")

## Proporción prom. de apartamentos en Marco Original (Cundinamarca):
0.2622034

cat("Proporción prom. de apartamentos en NO Probabilística:",
  mean(base_NP$TP14_2_TIP / base_NP$TVIVIENDA, na.rm=TRUE), "\n\n")

## Proporción prom. de apartamentos en NO Probabilística: 0.5448786

cat("Proporción prom. de apartamentos en Probabilística: ",
  mean(base_P$TP14_2_TIP / base_P$TOTAL_VIVIENDAS, na.rm=TRUE), "\n")

## Proporción prom. de apartamentos en Probabilística: 0.3406943

cat("Promedio de jóvenes (20-39) en Probabilística: ",
  mean(base_P$TP34_3_EDA + base_P$TP34_4_EDA), "\n")

## Promedio de jóvenes (20-39) en Probabilística: 126.5208
```

```
cat("Promedio de jóvenes (20-39) en NO Probabilística:",
mean(base_NP$TP34_3_EDA + base_NP$TP34_4_EDA), "\n")

## Promedio de jóvenes (20-39) en NO Probabilística: 150.1613
```

PSA segun valliant

```
# 1. Cargar librerías
library(dplyr)
```

```
# --- PREPARACIÓN DE LAS BASES SEGÚN EL DICCIONARIO ---
# Muestra Probabilística (S_a): Creamos el indicador muestra_id = 0
S_a <- base_P %>%
  mutate(
    muestra_id = 0,
    # Homologamos el nombre para que coincida con la no probabilística
    prop_apartamentos = TP14_2_TIP / TOTAL_VIVIENDAS,
    poblacion_joven = TP34_3_EDA + TP34_4_EDA
  ) %>%
  # Seleccionamos el ID, las variables auxiliares (X) y el identificador
  # de muestra
  select(COD_DANE_A, prop_apartamentos, poblacion_joven, muestra_id, PESO)

# Muestra No Probabilística (S_b): Creamos el indicador muestra_id = 1
# Nota: Aquí debes incluir también tu VARIABLE OBJETIVO (la que quieres
# estimar, ej: Y)
S_b <- base_NP %>%
  mutate(
    muestra_id = 1,
    prop_apartamentos = TP14_2_TIP / TVIVIENDA,
    poblacion_joven = TP34_3_EDA + TP34_4_EDA,
    PESO = 1 # peso de diseño neutro para S_b
  ) %>%
  select(COD_DANE_A, prop_apartamentos, poblacion_joven,
    muestra_id, TP19_INTE1, PESO)
```

```
# 2. UNIÓN DE MUESTRAS (Pool)
# Tal como indica tu documento: pool <- bind_rows(S_a, S_b)
pool <- bind_rows(S_a, S_b)
```

```
# 3. MODELO DE PROPENSIÓN (Clasificador Logístico)
# Modelamos la pertenencia a la muestra no probabilística usando las
# variables que causaron el sesgo
modelo_psa <- glm(muestra_id ~ prop_apartamentos + poblacion_joven,
  data = pool,
  family = binomial(link = "logit"),
  weights = ifelse(pool$muestra_id == 0,
    pool$PESO, # el peso que ya tienes en
```

```

base_P
                                1))                                # S_b no tiene
peso de diseño

# Predecir las propensidades (probabilidades de inclusión simuladas)
pool$propensidad <- predict(modelo_psa, type = "response")

# 4. CÁLCULO DE PESOS DE AJUSTE (Valliant)
# Filtramos solo la muestra No Probabilística y aplicamos la fórmula:  $(1 - p) / p$ 
S_b_ajustada <- pool %>%
  filter(muestra_id == 1) %>%
  mutate(peso = (1 - propensidad) / propensidad)

```

estimación de la variable de interes

```

# 5. ESTIMACIÓN FINAL DE TU VARIABLE DE INTERÉS (Y)

# Referencia desde la muestra probabilística
media_referencia <- sum(base_P$VIVIENDAS_INTERNET * base_P$PESO, na.rm =
TRUE) /
  sum(base_P$PESO, na.rm = TRUE)

# Estimación Sesgada (Sin ponderar)
media_sesgada <- mean(S_b_ajustada$TP19_INTE1, na.rm = TRUE)

# Estimación Ajustada usando Los Pesos de Valliant
media_ajustada <- sum(S_b_ajustada$TP19_INTE1 * S_b_ajustada$peso, na.rm
= TRUE) /
  sum(S_b_ajustada$peso, na.rm = TRUE)

# --- RESULTADOS ---
cat("Estimación de Referencia (Probabilística ponderada):",
round(media_referencia, 2), "\n")

## Estimación de Referencia (Probabilística ponderada): 14.31

cat("Estimación Sesgada (No Probabilística):", round(media_sesgada, 2),
"\n")

## Estimación Sesgada (No Probabilística): 83.58

cat("Estimación Ajustada (Método Valliant):  ", round(media_ajustada,
2), "\n")

## Estimación Ajustada (Método Valliant):    40.74

```

Grafico de correccion de sesgo

```
library(ggplot2)

# 1. Preparar Los datos para La gráfica
# Necesitamos la muestra probabilística (referencia) y La no
# probabilística (con y sin peso)
graf_prob <- S_a %>% select(prop_apartamentos) %>% mutate(Distribucion =
"Muestra Probabilística (Referencia)")
graf_np <- S_b_ajustada %>% select(prop_apartamentos, peso)

# 2. Construcción del gráfico con ggplot2
ggplot() +
  # Línea/Área de La Muestra Probabilística (Base de Referencia)
  geom_density(data = graf_prob, aes(x = prop_apartamentos, fill =
Distribucion),
              alpha = 0.4, color = "grey30", linewidth = 0.6) +

  # Línea/Área de La Muestra No Probabilística SEEGADA (Sin usar Los
# pesos)
  geom_density(data = graf_np, aes(x = prop_apartamentos, fill = "Muestra
No Probabilística (Sesgada)",
              alpha = 0.4, color = "red", linewidth = 0.6) +

  # Línea/Área de La Muestra No Probabilística AJUSTADA (Usando weight =
# peso)
  geom_density(data = graf_np, aes(x = prop_apartamentos, weight = peso,
fill = "Muestra Ajustada (Valliant)",
              alpha = 0.4, color = "blue", linewidth = 0.7) +

  # 3. Personalización de colores e idéntica estética a tu PDF
  scale_fill_manual(values = c(
    "Muestra Probabilística (Referencia)" = "grey60",
    "Muestra No Probabilística (Sesgada)" = "#E41A1C",           # Rojo
    "Muestra Ajustada (Valliant)"         = "#377EB8"           # Azul de
institucional de sesgo
corrección
  )) +

  # 4. Etiquetas del gráfico
  labs(
    title = "Corrección del Sesgo de Selección vía PSA",
    subtitle = "Ajuste de la distribución de la proporción de
apartamentos mediante pesos de propensión",
    x = "Proporción de Apartamentos por Manzana",
    y = "Densidad",
    fill = "Distribución"
  ) +
```

```
# 5. Formato limpio
theme_minimal(base_size = 12) +
theme(
  plot.title = element_text(face = "bold", size = 14),
  legend.position = "right",
  panel.grid.minor = element_blank()
)
```

Corrección del Sesgo de Selección vía PSA

Ajuste de la distribución de la proporción de apartamentos me

